

ReViT 方法核心总结


该文章提出了一种改进视觉 Transformer (ViT) 的 残差注意力学习机制 (ReViT)，旨在解决 ViT 深层网络中的 特征崩溃 (Feature Collapse) 问题。以下是方法的核心要点：

1. 问题背景

- ViT 的局限性：**深层网络中的自注意力机制 (Self-Attention) 导致 低层次视觉特征丢失 (如边缘、纹理)，特征过度全局化。
 - 后果：**影响模型在分类、检测等任务中的准确性和鲁棒性，尤其在数据量较小的场景下表现更差。
-

2. 核心创新：注意力残差连接

- 核心思想：**通过 跨层残差连接传递注意力信息，保留浅层的局部特征，并与深层的全局特征融合。
- 实现方式：**



- i. **注意力信息传递**: 在相邻 Transformer 层之间，将前一层的注意力图（Attention Maps）以残差形式传递给当前层。
- ii. **置换不变聚合函数**: 使用加权平均或拼接等方式融合跨层注意力信息，避免引入额外参数。
- iii. **不改变原架构**: 仅在原有 ViT 基础上增加轻量级残差连接，保持计算效率。

3. 关键优势


- **缓解特征崩溃**: 通过残差连接保留低层次特征，增加特征多样性。特征崩溃是 ViT 架构中常见的现象。它指的是随着网络深度的增加，从不同图像块中提取的特征失去其独特性，变得越来越相似或难以区分的现象。这种现象主要是由于 ViT 中使用的注意力机制的性质造成的。

- **兼容性：**可无缝集成到多尺度 Transformer 架构（如 MViT2、Swin）中，支持分类、检测、分割等任务。
- **低计算开销：**相比现有方法（如添加并行 MLP 层），仅增加少量计算量。

4. 实验验证

- **数据集：**ImageNet1K、CIFAR 系列、Oxford Flowers-102 等分类任务；COCO2017 检测与分割任务。
- **结果：**
 - **分类任务：**ReViT 在 ImageNet1K 上 Top-1 准确率提升 1.2%-2.5%，小数据集（如 CIFAR-100）提升更显著。
 - **注意力分析：**非局部性指标（Non-locality Metric）显示 ReViT 保留更多局部信息。
 - **鲁棒性：**在噪声、遮挡等扰动下表现更稳定。

SAN:



租不到显卡，在本地重新配置了 SAN 的环境进行 debug。代码没改完，下周继续改。